Universidad Peruana de Ciencias Aplicadas
Facultad de Ingeniería



Curso: Matemática Discreta

Profesor: Germain Cardenas Zavala

Sección: 3638

Proyecto: Cadenas de Markov

Informe entregable de la semana 3
"Aplicación de la Cadena de Markov en programación y en la vida real"

Integrantes	Código
George Morote, Gian Yamil	U202312450
Chuquisengo Gomez, Aldighieri Farid	U202323541
Ramos Minaya, Piero Victor Oswaldo	U202423976
Yupanqui De la Cruz, Juan Manuel	U20231E910
Gomez Flores Sebastian Matias	u20213F126

Link del vídeo: https://youtu0.be/ZUwxuTU5shc

2025-01

Índice

1. **Introducción**
2. **Objetivos**

   2.1 Objetivo General

   2.2 Objetivos Específicos

3. **Marco teórico**

   3.1. ¿Qué es un vector de probabilidades?

   3.2. ¿Qué es una matriz estocástica?

   3.3. ¿Qué es la Cadena de Markov?

   3.4. ¿Qué es el modelo de Leslie?

4. **Ejemplos**
5. **Resultados del programa**
6. **Diagramas**
7. **Aplicaciones**
8. **Conclusiones y Recomendaciones**
9. **Bibliografía**

2025-01

1. Introducción

Las cadenas de Markov es un modelo matemático que describe un sistema que transita entre diferentes estados de manera probabilística. Su simplicidad y versatilidad la han convertido en una herramienta fundamental en diversas áreas, desde la programación hasta la toma de decisiones en la vida cotidiana.Veremos cómo se aplican en el desarrollo de algoritmos, en la predicción de comportamientos y en la optimización de procesos. A través de ejemplos concretos, demostraremos su relevancia y utilidad en la resolución de problemas complejos, tanto en el ámbito tecnológico como en situaciones cotidianas. En nuestro caso, se desea analizar el comportamiento de una secuencia de estados climáticos (por ejemplo, nublado, parcialmente nublado, etc.) mediante un modelo de cadenas de Markov. Para ello, se debe:
Generar una secuencia aleatoria de entre 20 y 40 estados climáticos, donde cada estado puede ser:
-NU (nublado)
-P (parcialmente nublado)
-PS (parcialmente soleado)
-SO (soleado)
A partir de esta secuencia, se debe: Contar las transiciones de un estado al siguiente. Construir una matriz de transición que indique cuántas veces ocurre cada cambio de estado.

2. Objetivos

2.1 Objetivos generales

Profundizar el estudio de las Cadenas de Markov y su implementación en diversos ámbitos, como la programación y las aplicaciones del mundo real, mediante el uso del lenguaje de programación C + +.

2.2 Objetivos específicos

-Implementación del trabajo de programación

- Desarrollo del conocimiento de matemática discreta y aprender la implementación del curso dentro de la programación.

- Desarrollar y programar simulaciones que permitan observar y analizar el programa del problema propuesto.

- Construir una matriz estocástica que represente las probabilidades de transición entre diferentes estados climáticos simulados.

-Resolución del problema propuesto del proyecto: Modelo de Leslie en ecología.

3. 3. Marco Teórico

3.1. Vectores de probabilidad

Un vector de probabilidades es un conjunto ordenado de números reales no negativos cuya suma total es igual a 1. Cada número del vector representa la probabilidad de que ocurra un determinado estado. Por ejemplo, el vector [0.6, 0.3, 0.1] podría representar un 60% de probabilidad de que el clima está soleado, 30% de que esté parcialmente nublado y 10% de que llueva.

En el contexto de las cadenas de Markov, los vectores de probabilidad representan el estado del sistema en un instante determinado, indicando la probabilidad de estar en cada uno de los estados posibles.

3.2. Matriz estocástica

Una matriz estocástica es una matriz cuadrada en la que cada fila representa un estado actual, y cada columna un posible estado futuro. Los elementos de la matriz son probabilidades, por lo tanto, toman valores entre 0 y 1, y la suma de los elementos de cada fila es igual a 1.

Estas matrices permiten modelar las probabilidades de transición entre estados. En este proyecto, la matriz estocástica refleja las probabilidades de pasar de un tipo de clima a otro (por ejemplo, de nublado a soleado). Multiplicando un vector de probabilidad inicial por la matriz estocástica, se puede obtener la distribución de probabilidad para el siguiente día.

3.3. Cadena de Markov

Una cadena de Markov es un modelo matemático utilizado para describir un proceso que cambia de estado en forma secuencial, donde la probabilidad del siguiente estado depende únicamente del estado actual. Esta propiedad se conoce como propiedad de Markov.

En otras palabras, el futuro del sistema depende solo del presente, no del pasado. Por ejemplo: si hoy está soleado, y se sabe que hay un 70% de que mañana también lo esté, esa información es suficiente para predecir el clima, sin necesidad de analizar cómo estuvo el clima en días anteriores.

En este proyecto, se utiliza una cadena de Markov de tiempo discreto y estado finito para simular cómo cambia el clima a lo largo de varios días. A partir de una secuencia de estados aleatorios y del conteo de transiciones entre ellos, se construye la matriz estocástica. Esta matriz permite hacer predicciones basadas únicamente en el estado actual.

3.4. Teoría de Probabilidades

La teoría de probabilidades es una rama de la matemática que estudia la posibilidad de que ocurra un evento (Wolfram MathWorld). En términos simples, mide cuán probable es que ocurra un determinado resultado dentro de un conjunto de todos los posibles.Se expresa mediante un número entre 0 y 1:

- 0 significa que el evento es imposible.
- 1 significa que el evento es seguro.
- Valores entre 0 y 1 indican niveles de certeza intermedios. Ejemplo: Al lanzar una moneda justa, la probabilidad de que salga cara es 0.5, ya que hay dos resultados igualmente posibles (cara o cruz).

Modelos de probabilidad Existen varios enfoques teóricos sobre cómo entender y definir la probabilidad:

1. Enfoque clásico:
   - Define la probabilidad como el cociente entre los casos favorables y los casos posibles, suponiendo que todos son igualmente probables.

$$P(A) = \frac{número\ de\ casos\ favorables\ a\ A}{número\ \ total\ de\ casos\ favorables}$$

   - Ejemplo: Lanzar un dado. Probabilidad de que salga un 4:

$$P(4) = \frac{1}{6}$$

2. Enfoque frecuentista:
   - Define la probabilidad como el límite de la frecuencia relativa de un evento cuando el experimento se repite muchas veces.
   - Ejemplo: Si lanzamos una moneda 1,000 veces y sale cara 502 veces, la frecuencia relativa es 0.502.

3. Enfoque bayesiano (subjetivo):
   - Considera la probabilidad como una medida del grado de creencia o incertidumbre subjetiva respecto a un evento.
   - Se actualiza con nueva información mediante el teorema de Bayes.

Elementos básicos

- Experimento aleatorio: Proceso cuyo resultado no puede preverse con certeza (ej.: lanzar un dado).
- Espacio muestral (S): Conjunto de todos los posibles resultados.
- Evento (A): Subconjunto del espacio muestral (el resultado que nos interesa).

Reglas básicas del cálculo de probabilidades :

1. Probabilidad de un evento seguro:

$P(S) = 1$

2. Probabilidad de un evento imposible:

$P(\emptyset) = 0$

3. Complemento de un evento:

$P(no\ A) = 1 - P(A)$

4. Unión de dos eventos (si son mutuamente excluyentes):

$P(A \cup B) = P(A) + P(B)$

5. Intersección de dos eventos (si son independientes):

$P(A \cap B) = P(A) \cdot P(B)$

Tipos de eventos

- Simples: Contienen un solo resultado del espacio muestral.
- Compuestos: Contienen dos o más resultados.
- Mutuamente excluyentes: No pueden ocurrir al mismo tiempo.
- Independientes: La ocurrencia de uno no afecta al otro.

4. **Ejemplo 1:**Predicción simple del clima diario

   Contexto:

   Una ciudad tiene tres posibles condiciones climáticas diarias: SO = Soleado, NU = Nublado y LL = Lluvioso.

   Probabilidades de transición:

   - Desde SO: 70% SO, 20% NU, 10% LL

   - Desde NU: 40% SO, 40% NU, 20% LL

   - Desde LL: 30% SO, 30% NU, 40% LL

   Matriz de transición P:

   | De / A | SO | NU | LL |

   |--------|------|------|------|

   | SO | 0.70 | 0.20 | 0.10 |

   | NU | 0.40 | 0.40 | 0.20 |

   | LL | 0.30 | 0.30 | 0.40 |

   Vector de estado inicial:

   v0 = [1, 0, 0] (100% probabilidad de SO)

   Día 1:

   v1 = v0 * P = [0.70, 0.20, 0.10]

   Día 2:

   v2 = v1 * P = [0.60, 0.25, 0.15]

   Día 3:

   v3 = v2 * P = [0.565, 0.265, 0.17]

   Resultado:

   Día 1: 70% SO, 20% NU, 10% LL

   Día 2: 60% SO, 25% NU, 15% LL

Día 3: 56.5% SO, 26.5% NU, 17% LL

Se usa una cadena de Markov, donde el clima de un día depende solo del día anterior. La predicción se hace multiplicando el vector de estado actual por una matriz de transición de probabilidades para obtener la probabilidad del clima del día siguiente.

Ejemplos 2 Predicción simple del clima con cadena de markov

Contexto:
Una ciudad tiene tres posibles condiciones climáticas diarias: soleado, nublado y lluvioso. Se ha observado históricamente que si hoy está soleado, hay un 70% de probabilidad de que mañana también lo esté, 20% de que esté nublado y 10% de que llueva.

Aplicación de la cadena de Markov:
Se construye una matriz de transición con estas probabilidades y se utiliza para predecir el clima de los días siguientes, basándose únicamente en el clima de hoy. Esto permite generar pronósticos a corto plazo sin necesidad de analizar todos los días anteriores, solo el estado actual.

Predicción del Clima con Cadenas de Márkov
Supuesto:
Se observaron 10 días de clima con los siguientes estados:
["SO", "SO", "PS", "NU", "P", "P", "NU", "SO", "PS", "SO"]

Paso 1: Contar transiciones entre estados
Estados: SO = Soleado, PS = Parcialmente Soleado, NU = Nublado, P = Precipitaciones

Transiciones:
De -> A	SO	PS	NU	P
SO	1	1	0	0
PS	0	0	1	0
NU	1	0	0	1
P	0	0	1	1

Paso 2: Matriz Estocástica (normalizada por fila):
De / A	SO	PS	NU	P
SO	0.5	0.5	0.0	0.0
PS	0.0	0.0	1.0	0.0
NU	0.5	0.0	0.0	0.5
P	0.0	0.0	0.5	0.5

Paso 3: Predicción desde estado PS

Día 1: v1 = [0.0, 0.0, 1.0, 0.0] -> NU (100%)
Día 2: v2 = [0.5, 0.0, 0.0, 0.5] -> 50% SO, 50% P -> elegimos P
Día 3: v3 = [0.0, 0.0, 0.5, 0.5] -> 50% NU, 50% P -> elegimos NU

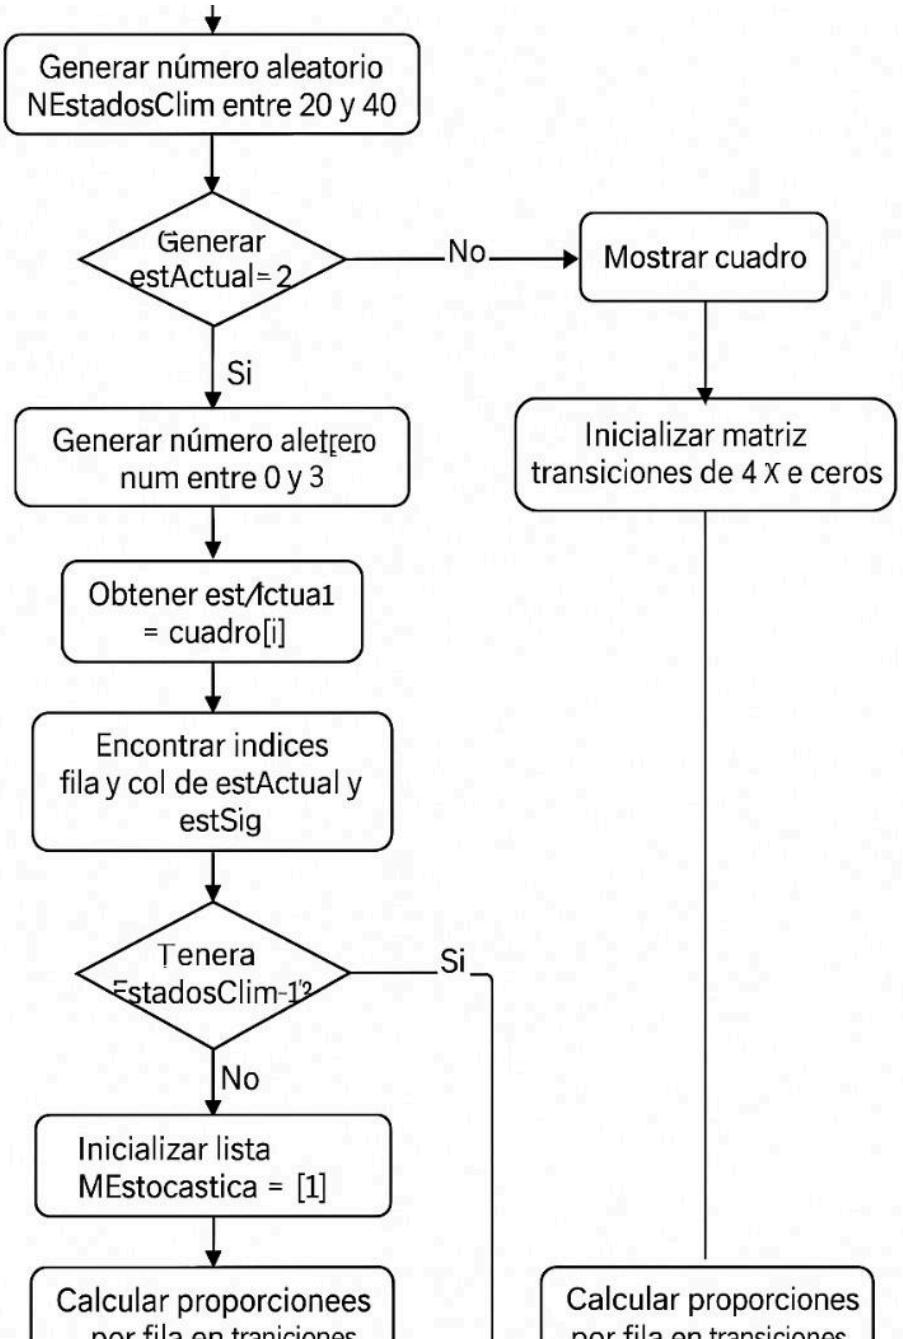
Resultado:

- Día 1: NU
- Día 2: P
- Día 3: NU

Resultado:
- Día 1: NU
- Día 2: P
- Día 3: NU

Criterios:
- Se escoge el estado con mayor probabilidad.
- En caso de empate, se selecciona aleatoriamente o se indica la ambigüedad.

5. **Diagramas :** Diagrama de flujo



6. Código del Proyecto

```
import random

estadosPosibles = ["NU", "P", "PS", "SO"]

def ValidarN():
    while True:
        try:
            n = int(input("Ingrese un número entre el 20 y el 40: "))
            if 20 <= n <= 40:
                return n
            else:
                        print("No ha ingresado un número dentro del rango
permitido")
        except ValueError:
            print("No ha ingresado un número válido")

def generarCuadro(n):
    cuadro = []
    for i in range(n):
        cuadro.append(random.choice(estadosPosibles))
    return cuadro

def actualizarMatriz(matriz, estado_anterior, estado_actual):
    if estado_anterior is not None:
        i = estadosPosibles.index(estado_anterior)
        j = estadosPosibles.index(estado_actual)
        matriz[i][j] += 1
```

```
    return matriz

def calcularMatrizEstocastica(transiciones):
    matrizEstocastica = []
    for fila in transiciones:
        total = sum(fila)
        nuevaFila = []
        for x in fila:
            if total == 0:
                nuevaFila.append(0.0)
            else:
                valor = round(x / total, 2)
                nuevaFila.append(valor)
        matrizEstocastica.append(nuevaFila)
    return matrizEstocastica

def imprimirMEstocastica(matriz):
    print("\nMatriz estocástica actualizada:")
    print("      NU   P    PS   SO")
    for i in range(4):
        print(f"{estadosPosibles[i]:<3}  ", end="")
        for j in range(4):
            print(f"{matriz[i][j]:<5}", end=" ")
        print()

def ImprimirElCuadro(cuadro, bloque=5):
    total = len(cuadro)
    bloques = (total + bloque - 1) // bloque

    print("\nHistorial de estados climáticos:\n")

    for b in range(bloques):
        inicio = total - (b + 1) * bloque
        fin = total - b * bloque
        if inicio < 0:
            inicio = 0

        for i in range(fin - 1, inicio - 1, -1):
            dia = f"DÍA {i+1}" if i != total - 1 else "HOY"
            print(f"| {dia:<7}", end=" ")
        print("|")

        for i in range(fin - 1, inicio - 1, -1):
```

```
            print(f"| {cuadro[i]:<7}", end=" ")
        print("|\n")

def simulacionDinamica():
    print("---- Bienvenido al programa de cadenas de Markov ----\n")
    NEstadosClim = ValidarN()
    cuadro = generarCuadro(NEstadosClim)

    # Inicializar matriz de transiciones
    transiciones = [[0]*4 for _ in range(4)]

    # Calcular transiciones iniciales
    for i in range(len(cuadro) - 1):
                transiciones = actualizarMatriz(transiciones, cuadro[i],
cuadro[i+1])

    while True:
        ImprimirElCuadro(cuadro)
        matriz = calcularMatrizEstocastica(transiciones)
        imprimirMEstocastica(matriz)

        opcion = input("\n¿Desea agregar un nuevo estado? (s/n): ").lower()
        if opcion != 's':
            break

        nuevo_estado = random.choice(estadosPosibles)
        cuadro.append(nuevo_estado)

        # Actualizar matriz de transiciones con el nuevo estado
        if len(cuadro) > 1:
                transiciones = actualizarMatriz(transiciones, cuadro[-2],
cuadro[-1])

        print(f"\nSe ha agregado el estado: {nuevo_estado}")

simulacionDinamica()
```

7. Aplicación del Proyecto

1) **El programa genera la siguiente secuencia de estados climáticos para 20 números:**

   [PS, P, PS, SO, SO, NU, NU, P, P, PS, SO, SO, NU, PS, P, PS, SO, P, PS, SO]

   El programa analiza cuántas veces cambia un estado a otro. Por ejemplo:

- De PS a SO ocurrió 3 veces.
- De P a PS ocurrió 2 veces.
- De NU a P ocurrió 1 vez.

Se construye una matriz con las **frecuencias** de transiciones entre cada estado.

	NU	**P**	**PS**	**SO**
NU	**0.00**	**0.50**	**0.50**	**0.00**
P	**0.00**	**0.25**	**0.50**	**0.25**
PS	**0.00**	**0.00**	**0.25**	**0.75**
SO	**0.25**	**0.00**	**0.25**	**0.50**

2) **Supongamos que el usuario ingresa un historial de 25 días y el programa genera aleatoriamente la siguiente secuencia climática:**

   [NU, P, P, PS, SO, NU, PS, PS, SO, SO, P, P, NU, NU, PS, SO, P, P, PS, SO, SO, NU, P, PS, SO]

El programa analiza cuántas veces ocurre cada cambio entre un estado y otro:

- De NU a P: 2 veces
- De P a P: 2 veces
- De P a PS: 3 veces
- De PS a SO: 4 veces
- De SO a NU: 2 veces
- De SO a P: 1 vez

Estos datos se usan para construir la matriz de frecuencias de transición.

	NU	P	PS	SO
NU	0.00	0.67	0.33	0.00
P	0.00	0.40	0.60	0.00
PS	0.00	0.00	0.10	0.90
SO	0.40	0.20	0.00	0.40

Resultados del Programa

```
PS C:\Users\Sebastian\Downloads\Mate.programa> python trabajo.py
---- Bienvenido al programa de cadenas de Markov ----

Ingrese un número entre el 20 y el 40: 35

Historial de estados climáticos:

| HOY     | DÍA 34  | DÍA 33  | DÍA 32  | DÍA 31  |
| SO      | NU      | NU      | SO      | NU      |

| DÍA 30  | DÍA 29  | DÍA 28  | DÍA 27  | DÍA 26  |
| NU      | PS      | SO      | P       | NU      |

| DÍA 25  | DÍA 24  | DÍA 23  | DÍA 22  | DÍA 21  |
| SO      | NU      | P       | SO      | PS      |

| DÍA 20  | DÍA 19  | DÍA 18  | DÍA 17  | DÍA 16  |
| P       | P       | SO      | PS      | NU      |

| DÍA 15  | DÍA 14  | DÍA 13  | DÍA 12  | DÍA 11  |
| PS      | SO      | NU      | NU      | PS      |

| DÍA 10  | DÍA 9   | DÍA 8   | DÍA 7   | DÍA 6   |
| SO      | PS      | P       | SO      | PS      |

| DÍA 5   | DÍA 4   | DÍA 3   | DÍA 2   | DÍA 1   |
| PS      | NU      | PS      | NU      | P       |
```

```
Matriz estocástica:
      NU   P    PS   SO
NU   0.27  0.09  0.27  0.36
P    0.33  0.17  0.33  0.17
PS   0.44  0.0   0.11  0.44
SO   0.25  0.38  0.38  0.0
Desea seguir analizando los estados climaticos de los proximos dias?
1.SI 2.NO :1
Ingrese la cantidad de dias que va analizar, que sea menor a 5:3
Ingrese la cantidad de dias que va analizar, que sea menor a 5:

Predicción de estados climáticos para los próximos 3 días:

Día 1: P
Día 2: P
Día 3: SO

Nuevo historial incluyendo los días predichos:
```

```
Historial de estados climáticos:

| HOY     | DÍA 37  | DÍA 36  | DÍA 35  | DÍA 34  |
| SO      | P       | P       | SO      | NU      |

| DÍA 33  | DÍA 32  | DÍA 31  | DÍA 30  | DÍA 29  |
| NU      | SO      | NU      | NU      | PS      |

| DÍA 28  | DÍA 27  | DÍA 26  | DÍA 25  | DÍA 24  |
| SO      | P       | NU      | SO      | NU      |

| DÍA 23  | DÍA 22  | DÍA 21  | DÍA 20  | DÍA 19  |
| P       | SO      | PS      | P       | P       |

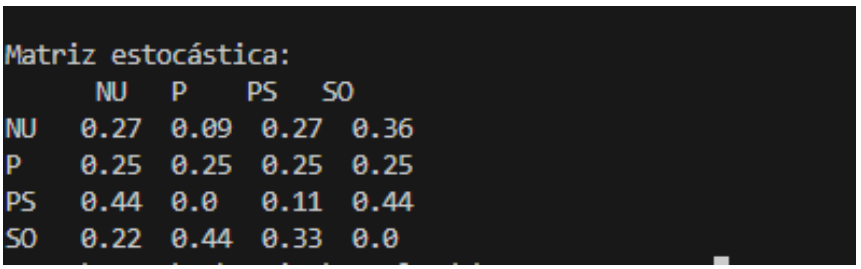
| DÍA 18  | DÍA 17  | DÍA 16  | DÍA 15  | DÍA 14  |
| SO      | PS      | NU      | PS      | SO      |

| DÍA 13  | DÍA 12  | DÍA 11  | DÍA 10  | DÍA 9   |
| NU      | NU      | PS      | SO      | PS      |

| DÍA 8   | DÍA 7   | DÍA 6   | DÍA 5   | DÍA 4   |
| P       | SO      | PS      | PS      | NU      |

| DÍA 3   | DÍA 2   | DÍA 1   |
| PS      | NU      | P       |


Nueva matriz estocástica con los datos extendidos:
```



8. Conclusiones y recomendaciones

El modelo implementado representa una herramienta didáctica efectiva para ilustrar cómo las cadenas de Markov pueden capturar transiciones entre estados discretos, como en el caso de condiciones climáticas. A través de este ejercicio, se evidenció que:

- Aunque el modelo cumple su propósito pedagógico, su aplicación en escenarios reales requeriría una mayor granularidad en los estados, el uso de datos históricos reales en lugar de valores aleatorios, y posibles extensiones como los Modelos Ocultos de Markov para representar factores no observables directamente.

- Se recomienda incorporar técnicas de suavizado, como el suavizado de Laplace, para evitar transiciones con probabilidad cero, especialmente cuando se trabaja con conjuntos de datos pequeños.

- La inclusión de condiciones climáticas adicionales (como “tormenta” o “nieve”) podría enriquecer el modelo y hacerlo más representativo de la realidad.

- Finalmente, se sugiere evaluar si la matriz de transición converge hacia una distribución estacionaria, lo cual indicaría la existencia de un equilibrio climático teórico.

Estos resultados y reflexiones permiten comprender tanto las fortalezas como las limitaciones del modelo, sentando las bases para futuros trabajos más robustos y orientados a aplicaciones reales.

9. Fuentes bibliográficas

-Jimenez, E. (2019). Cadenas de Markov espaciales para simular el crecimiento del Área Metropolitana de Toluca, 2017-2031. *Economía, sociedad y territorio. 19(60).* https://www.scielo.org.mx/scielo.php?pid=S1405-84212019000200109&script=sci_arttext#B34

-Scientia et Technica (2006). *Convergencia de LAS CADENAS DE Markov* https://revistas.utp.edu.co/index.php/revistaciencia/article/view/6195/3605

-Barriola, J. & Dotta, M. ¿Cómo funciona Google? El algoritmo pagerank, diagramas de grafos y cadenas de markov. Revista de Investigación en Modelos Matemáticos Aplicados a la Gestión y la Economía. 3. 9-30. https://www.economicas.uba.ar/wp-content/uploads/2016/04/2-%C2%BFC%C3%B3mo-funciona-google_-el-algoritmo-pagerank-diagramas-de-grafos-y-cadenas-de-markov.-Juan-Manuel-Barriola-y-Milena-Dotta-2.pdf

- Weisstein, E. W. (s.f.). *Probability*. Wolfram MathWorld. Recuperado el 22 de mayo de 2025, de https://mathworld.wolfram.com/Probability.html

-